Projet tutoré :Data Analysis

Analyse statistique d'une base de données pour étudier la chimio-diversité du vivant

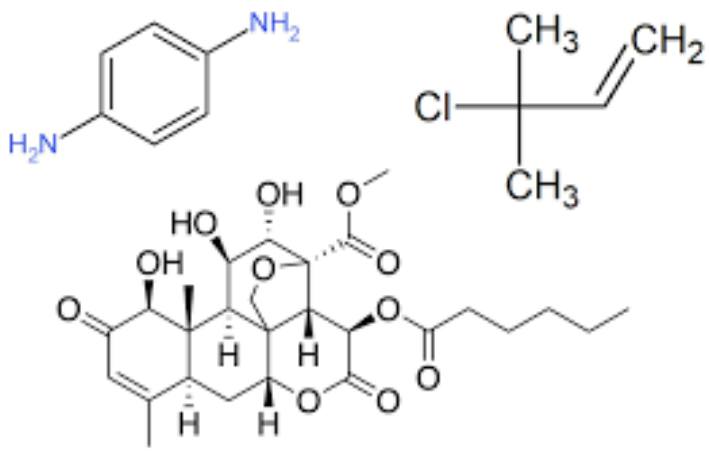

EL AZHAR / DIALLO / LOUNES
Encadré par : Solweigh HENNECHART, Sebastien DEJEAN
Toulouse
Université Paul Sabatier UT3
2023/2024

Table des matières

1 Présentation du sujet **2**
1.0.1 Science des données 2
1.0.2 La chimio-biodiversite 2
1.0.3 Sujet choisi 3
1.0.4 Contraintes 3
1.0.5 Étapes de résolution 4

2 Travail réalisé **5**
2.1 Environnement de travail 5
2.2 Analyse des données 5
2.3 Application de l'Analyse en Composantes Pricipales (ACP) . . . 20
2.3.1 Résultats 21
2.3.2 Conclusion de l'ACP) 23

3 Conclusion **24**

4 Bibliographie **25**

Chapitre 1

Présentation du sujet

1.0.1 Science des données

Ce projet tutoré explore le vaste domaine de la science des données, également connue sous le nom de "data science". Cette discipline moderne repose sur l'utilisation d'outils mathématiques, statistiques et informatiques pour analyser et exploiter l'énorme volume d'informations que notre société moderne accumule. Nous avons été spécifiquement confrontés à des défis liés à l'analyse de données, à l'apprentissage automatique et à la prévision, en nous appuyant sur la technologie informatique.
Dans ce rapport, nous décrirons nos stratégies pour relever ces défis et les techniques que nous avons utilisées.

1.0.2 La chimio-biodiversite

La biodiversité, définie comme la variété et l'abondance des formes de vie sur Terre, est au cœur des préoccupations scientifiques et environnementales. Au-delà de la diversité des espèces et des écosystèmes, un aspect essentiel de la biodiversité réside dans la variété des composés chimiques produits par les organismes vivants, plus connus sous le nom de chimio-diversité. Cette richesse chimique joue un rôle fondamental dans de nombreux processus biologiques, tels que la défense contre les prédateurs, la communication entre les espèces, ou encore l'adaptation aux conditions environnementales.

L'analyse de la chimio-diversité présente un défi scientifique de taille, nécessitant une approche intégrative combinant des connaissances en biologie, chimie et statistiques. En effet, la caractérisation de cette diversité requiert des méthodes statistiques sophistiquées capables de traiter des ensembles de données complexes et hétérogènes.

L'étude de la chimio-diversité du vivant nécessite une approche multidisciplinaire, combinant des connaissances en biologie, chimie et statistiques. En effet, pour comprendre la distribution et l'évolution des composés chimiques dans le règne vivant, il est essentiel de recourir à des méthodes d'analyse statistique adaptées. Dans cette optique, cette étude s'inscrit dans une démarche visant à explorer la chimio-diversité du vivant à travers une approche statis-

tique rigoureuse. En examinant la distribution, l'abondance et les relations entre les composés chimiques, nous cherchons à identifier les facteurs influençant la chimio-diversité. L'objectif est de déployer un ensemble d'outils et de méthodes statistiques afin de comprendre les motifs et les déterminants de la répartition des composés chimiques au sein des organismes vivants.

Pour comprendre pleinement la chimio-diversité et son impact sur la biodiversité, une question cruciale émerge : comment prédire l'origine biologique des organismes vivants à partir de la chimio-diversité ?

Cette problématique guide notre recherche en cherchant à déterminer si les caractéristiques chimiques des organismes peuvent être utilisées pour inférer leur origine biologique. En d'autres termes, nous explorons dans quelle mesure les données sur la chimio-diversité peuvent nous aider à comprendre les origines évolutives et les relations phylogénétiques entre les organismes.

1.0.3 Sujet choisi

Ce sujet de projet tutoré s'inscrit dans un travail plus global sur l'exploration de la chimiodiversité du vivant faisant l'objet d'une thèse débutée en octobre 2021 à l'interface entre la biologie et l'informatique. L'encadrement sera assuré par la doctorante en bio-informatique Solweig Hennechart et par l'ingénieur de recherche en statistique Sébastien Dejean. Ce sujet n'était pas un choix libre, mais plutôt une option parmi d'autres sur notre liste de sujets à choisir pour la distribution. Malgré cela, nous nous sommes investis dans le projet, même si le niveau de difficulté n'était pas celui auquel nous nous attendions. Cela ne nous a pas empêchés de progresser. Nous avons rencontré quelques contraintes, que nous aborderons bientôt.

1.0.4 Contraintes

Lors de notre travail sur le jeu de données, nous avons été confrontés à plusieurs contraintes. La première à laquelle nous avons dû faire face était liées à la base de données obtenue, comptant plus 280 000 entrées. Cette expérience constituait notre première immersion dans un projet réaliste avec une base de données concrète, et nous avons rencontré quelques difficultés à appliquer les connaissances acquises au cours de notre troisième année d'études. Ensuite, la gestion des données manquantes, présentes de manière non négligeable nécessitaient un traitement rigoureux pour éviter de biaiser nos résultats sans perdre trop d'information. La présence de variables qualitatives posait une contrainte supplémentaire en raison de la spécificité de notre étude. Nous ne pouvions pas utiliser les techniques d'encodage comme le one-hot encoding. Par ailleurs, le nombre important de variables quantitatives dans notre jeu de données a rendu l'analyse exploratoire plus complexe. Enfin, l'application et la compréhension de l'Analyse en Composantes Principales (ACP) se sont avérées assez compliqué. L'ACP nécessite une bonne compréhension de concepts mathématiques tels que les vecteurs propres et les valeurs propre.

1.0.5 Étapes de résolution

Concernant la gestion des valeurs nulles, nous avons décidé de remplacer les valeurs manquantes des variables quantitatives par les moyennes correspondantes, tandis que les valeurs manquantes des variables qualitatives ont été supprimées. Cela nous a permis de préserver l'intégrité des données sans introduire de biais significatifs. En ce qui concerne les colonnes qualitatives, nous avons maintenu ces variables dans leur format d'origine. Elles ont été traitées séparément dans nos analyses. Pour gérer le grand nombre de variables quantitatives, nous avons effectué une sélection des variables les plus pertinentes à l'aide de la technique de réduction de dimension (ACP). Pour rendre l'ACP plus accessible et compréhensible, nous avons intégré des visualisations et des explications pédagogiques détaillant chaque étape du processus, ce qui nous a aidés à interpréter les résultats de manière efficace. Ces stratégies nous ont permis de nettoyer et d'analyser l'ensemble de données, tout en surmontant les défis posés par les contraintes initiales.

Chapitre 2

Travail réalisé

2.1 Environnement de travail

Notre jeu de données provient de la version 2020 de Pharmakon, agrégation de onze sources de données de référence en produits naturels, publiques ou Lors de notre travail sur le jeu de données, nous avons été confrontés à plusieurs contraintes majeures. ontiennent des listes dont les éléments sont séparés par des pipe (—).
Il comporte 285 542 lignes et 84 colonnes. Ces colonnes se divisent en deux catégories :
-Les variables qualitative type object, au nombre de 10, représentent des informations sur la molécule : sa composition et son squelette, ses origines biologiques, sa classification chimique et sa formule moléculaire.
-Les 70 descripteurs, variables quantitatives de type float contiennent des données descriptives d'informations chimiques des molécules.

2.2 Analyse des données

Rentrons dans le vif du sujet, dans ce rapport, nous présentons une analyse complète des données issues du fichier 'datasetModelKnime.csv'.Cette etude vise à exlporer la structure des données, identifier des corrélations potentielles, et examiner la distribution de certaines catégories chimiques.

Pour débuter notre analyse, nous avons importé des bibliotèques pour la manipulation et la visualisation des données, notamment Pandas pour la gestion des datasets, NumPy pour les opérations mathématiques, Matplotlib et Seaborn pour la visualisation graphique.

La première étape de notre processus analytique a consisté à nettoyer les données pour assurer la qualité et la précision des résultats. Nous avons vérifié et traité les valeurs nulles et les doublons, permettant ainsi d'obtenir un dataset cohérent et prêt pour une analyse plus approfondie. Ce nettoyage est crucial pour éviter toute distorsion dans l'analyse des résultats.

L'analyse préliminaire du dataset révèle la présence de valeurs manquantes

parmi les variables. Afin d'optimiser le processus de nettoyage, un examen minutieux de ces valeurs nulles a été réalisé pour chaque colonne. Cette démarche permet de cibler précisément les corrections nécessaires. Par ailleurs, l'examen des données a confirmé l'absence de doublons, assurant ainsi la fiabilité des analyses futures. Après avoir éliminé les lignes contenant des valeurs manquantes, nous avons procédé à une vérification finale. En conséquence, nous disposons désormais d'un nouveau dataset comportant 166,732 lignes et 84 colonnes. Les colonnes ont été préservées dans leur intégralité, car il est possible qu'elles contiennent des informations essentielles pour nos analyses futures.

Une fois le nettoyage des données terminé, nous passons maintenant à l'analyse descriptive pour mieux comprendre les caractéristiques statistiques et les distributions des variables contenues dans notre dataset. Avant cela nous allons visualiser la distribution de nos données de chaque ligne ceci nous permettra d'avoir un peu de recul sur nos donées : La fonction df.nunique() dans Pandas est utilisée pour compter le nombre de valeurs uniques pour chaque colonne ou ligne dans un DataFrame. C'est une méthode utile pour comprendre la diversité de nos données.

Après analyse des valeurs uniques de chaque colonne, nous avons identifié la colonne 'kingdom' comme une variable catégorielle. Pour visualiser la distribution des catégories dans cette colonne, nous allons créer un graphique approprié. Nous ferons de même pour les colonnes 'taxa name' et 'classyfire class', afin de mieux comprendre la répartition des différentes classes et taxonomies présentes dans les données. Ces graphiques aideront à interpréter les données et à identifier les structures ou tendances significatives.

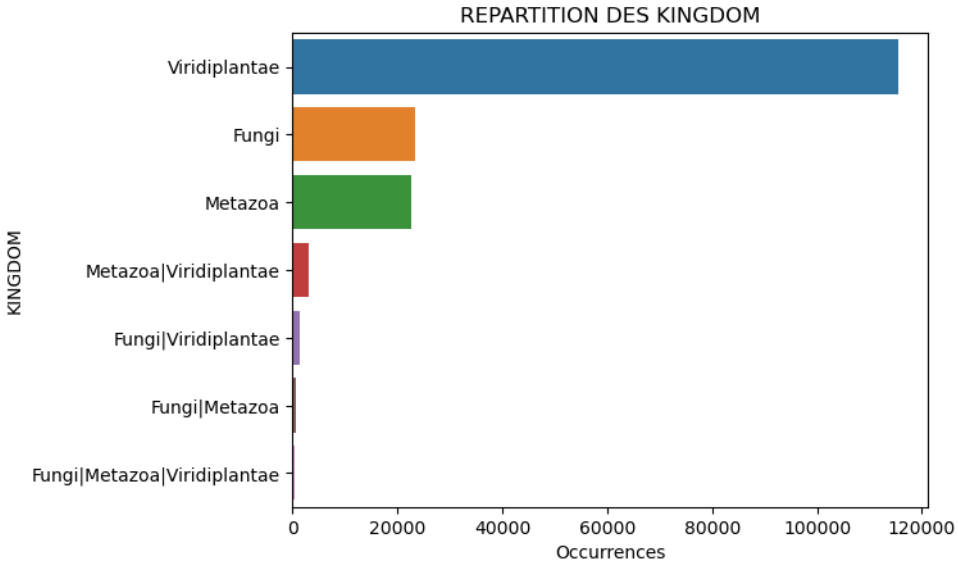

La répartition des données dans le graphique montre clairement que le royaume des "Viridiplantae" est de loin le plus représenté dans les données, avec une occurrence beaucoup plus élevée que les autres catégories. Les "Fungi" et les "Metazoa" suivent, mais avec des effectifs considérablement moins importants. Les

catégories combinées comme "Metazoa—Viridiplantae", "Fungi—Viridiplantae", "Fungi—Metazoa", et "Fungi—Metazoa—Viridiplantae" sont beaucoup moins fréquentes, ce qui suggère que les cas où les caractéristiques de plusieurs royaumes se chevauchent sont rares.

Cette distribution peut indiquer que les "Viridiplantae" sont particulièrement prédominants ou mieux documentés dans l'ensemble de données étudié. La rareté des catégories mixtes pourrait également signaler une séparation claire entre ces royaumes dans les conditions ou environnements étudiés, ou une focalisation moindre sur l'étude des interactions entre ces royaumes dans les données recueillies.

Ces observations pourraient guider des analyses plus poussées, notamment pour comprendre pourquoi les "Viridiplantae" sont si prédominants.

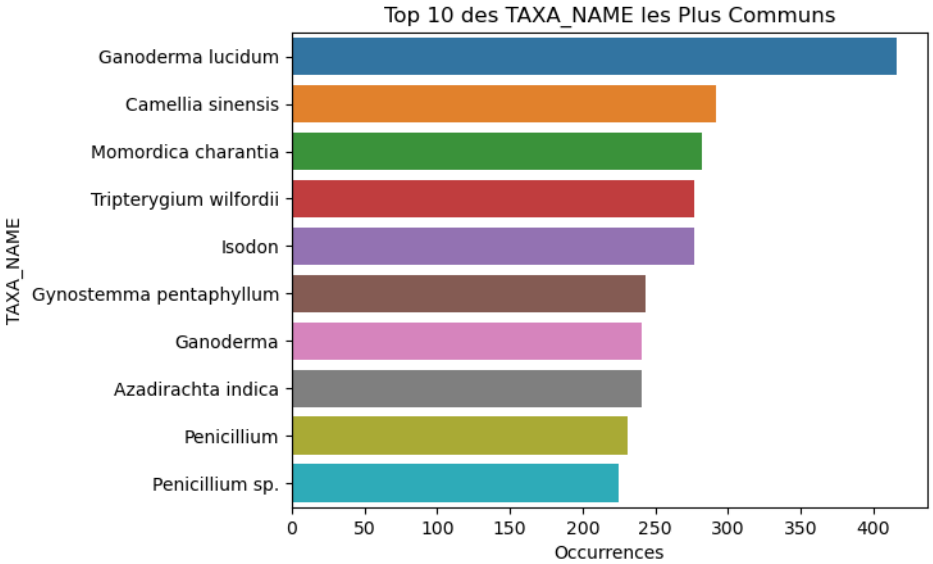

Ce graphique illustre le top 10 des noms taxonomiques les plus communs dans votre ensemble de données. "Ganoderma lucidum" se distingue comme étant le taxon le plus fréquent, suivi de près par "Camellia sinensis" et "Momordica charantia". Ces occurrences élevées peuvent refléter une importance particulière de ces espèces dans l'ensemble de données, que ce soit en raison de leur prévalence dans l'environnement étudié ou de leur pertinence dans le cadre de la recherche spécifique. L'intérêt pour des taxons variés tels que plantes, champignons et autres organismes indique une diversité dans les types de données collectées ou les objectifs de recherche. Cette visualisation aide à identifier rapidement les espèces les plus étudiées ou les plus représentées, fournissant une base pour des analyses plus ciblées ou approfondies concernant ces organismes.

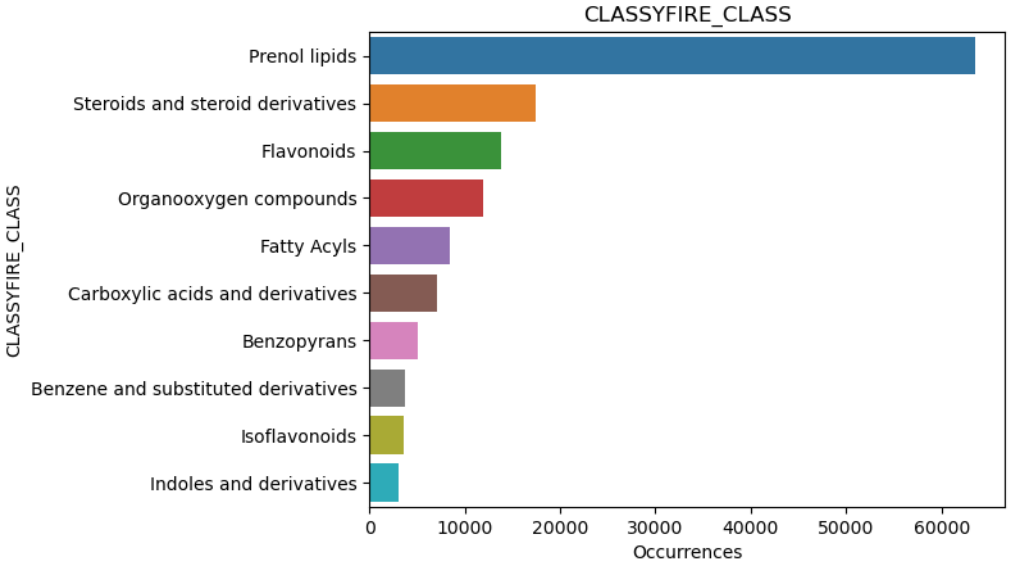

Ce graphique présente la répartition des classes chimiques selon le système de classification "ClassyFire". Il ressort clairement que les "Prenol lipids" sont la classe la plus fréquente dans l'ensemble de données, avec une prédominance notable par rapport aux autres catégories.

Les graphiques ensemble montrent que l'ensemble de données englobe une richesse en biodiversité et en biochimie, principalement centrée sur les plantes et les composés biologiquement significatifs. Les intérêts de recherche semblent se concentrer sur des organismes et des composés qui ont des implications pratiques importantes, que ce soit pour la santé, l'environnement, ou des applications industrielles.

Dans le cadre de notre exploration des diversités biochimiques présentes au sein des royaumes biologiques, nous avons analysé la distribution des classes chimiques dans trois kingdoms spécifiques : Metazoa, Viridiplantae et Fungi. Cette étude utilise des méthodes de visualisation des données pour représenter la prévalence des différentes classes chimiques à travers des graphiques à secteurs, permettant ainsi une compréhension rapide et visuelle des tendances biochimiques dominantes dans chaque kingdom. En se focalisant sur ces distributions, nous cherchons à identifier des modèles de concentration chimique qui pourraient refléter des adaptations écologiques ou des voies métaboliques privilégiées au sein de chaque groupe.

Distribution des Classes Chimiques dans le Kingdom des Fungi :

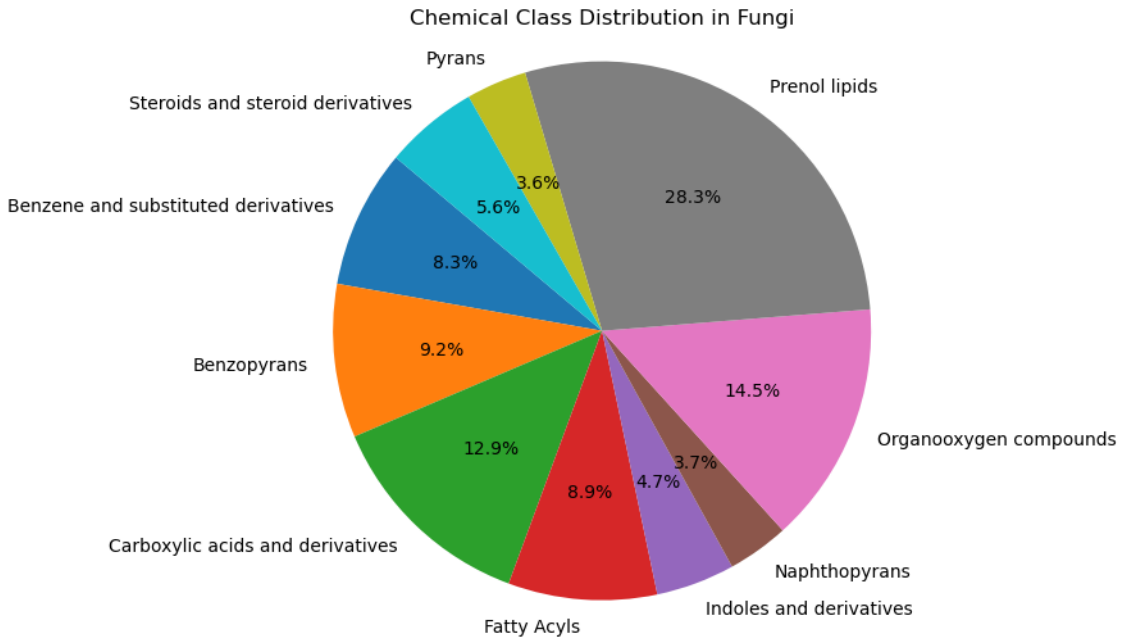

Le graphique montre une distribution intéressante des classes chimiques au sein du kingdom des Fungi, avec une prédominance notable de trois classes principales :

Prenol lipids (28.3%) : Ces composés constituent la classe la plus abondante chez les Fungi. Les prenol lipides jouent des rôles cruciaux dans les processus cellulaires, notamment en tant que précurseurs dans la synthèse de terpénoïdes et de stérols, essentiels pour la structure cellulaire et la signalisation. Organoxygen compounds (14.5%) : Cette classe inclut des composés qui contiennent de l'oxygène, tels que les alcools, les éthers et les époxides. Leur présence significative reflète les métabolismes sophistiqués des champignons pour la dégradation de la matière organique et la synthèse de composés bioactifs. Carboxylic acids and derivatives (12.9%) : Ces acides et leurs dérivés sont impliqués dans de nombreux processus biochimiques, y compris le cycle de Krebs pour la production d'énergie, ainsi que dans la biosynthèse de nombreux métabolites secondaires. Ces trois classes chimiques montrent non seulement une diversité fonctionnelle mais aussi une capacité d'adaptation et de survie des Fungi dans des environnements variés, en exploitant des voies métaboliques qui facilitent la production d'énergie, la communication cellulaire, et la défense contre les pathogènes.

Distribution des Classes Chimiques dans le Kingdom des Metazoa :

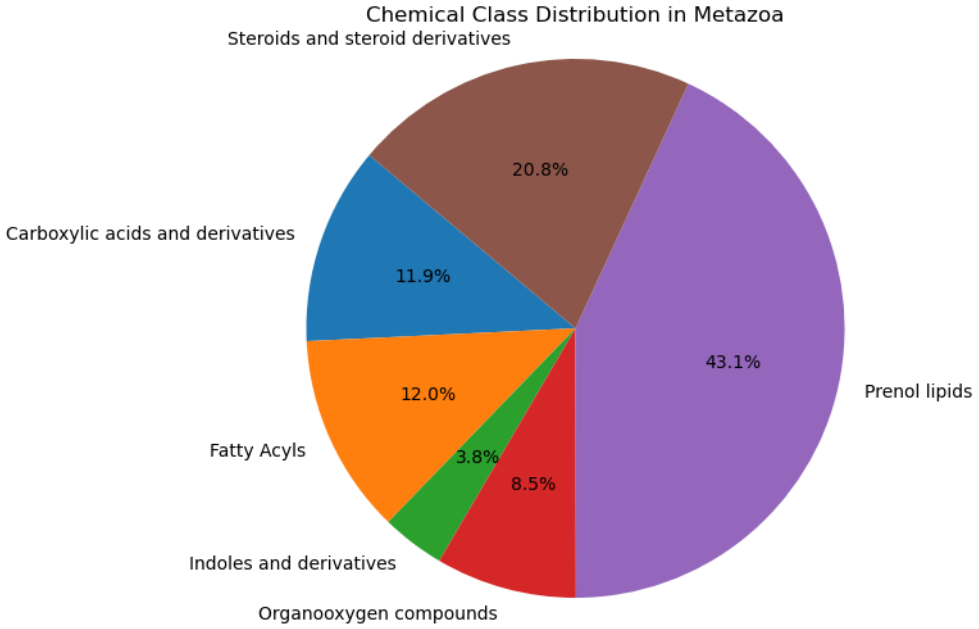

L'analyse révèle une forte concentration de prenol lipids, qui dominent à 43.1%, indiquant leur rôle crucial dans la biologie des Metazoa. Ces lipides sont essentiels dans plusieurs processus biologiques, notamment la signalisation cellulaire et la régulation hormonale. La présence significative de stéroïdes et de leurs dérivés, représentant 20.8%, soutient cette observation, car ces composés sont souvent impliqués dans les systèmes hormonaux et le métabolisme des lipides. Cette concentration des classes chimiques dans les prenol lipids et stéroïdes met en lumière l'adaptation des Metazoa à leurs environnements complexes via des mécanismes sophistiqués de régulation et de communication intercellulaire.

Distribution des Classes Chimiques dans le Kingdom des Viriplantae :

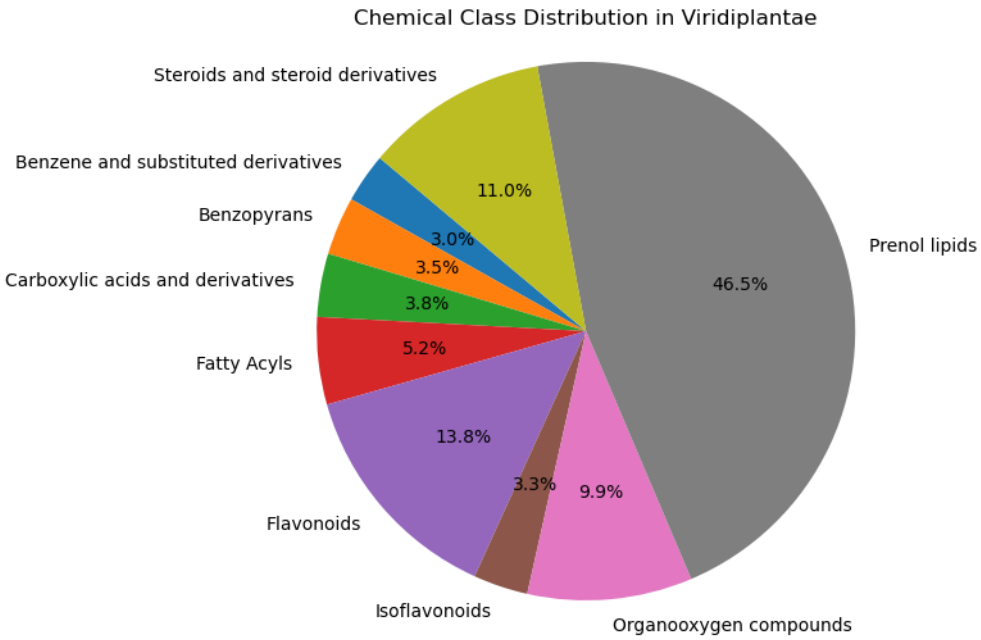

Le graphique montre que les prenol lipids sont de loin la classe chimique la plus abondante chez les Viridiplantae, représentant près de la moitié des classes détectées. Cette prévalence souligne leur rôle crucial dans les processus biologiques végétaux, notamment dans la construction et la maintenance des membranes cellulaires, ainsi que dans la biosynthèse des hormones végétales essentielles comme les gibbérellines et les cytokinines.

Les flavonoïdes, à 13.8%, et les organooxygen compounds, à 9.9%, sont également présents en quantités significatives, reflétant leur importance dans la protection contre le stress UV et les agresseurs pathogènes, ainsi que dans la modulation des interactions plantes-environnement.

Les autres classes comme les acides carboxyliques et leurs dérivés, et les isoflavonoïdes, bien que moins prédominants, jouent des rôles vitaux dans les métabolismes énergétique et défensif des plantes.

Cette distribution illustre l'adaptation des Viridiplantae à leurs niches écologiques à travers un éventail de mécanismes chimiques spécialisés Nous abordons à présent la phase d'analyse descriptive, une étape cruciale qui nous permet d'explorer en profondeur les propriétés statistiques des variables du dataset. Cette analyse vise à identifier les tendances, les écarts types, les médianes et autres mesures descriptives qui éclairent la distribution et la nature des données collectées. Elle est essentielle pour préparer le terrain à des investigations plus détaillées et à des analyses inférentielles ultérieures.

L'examen des distributions chimiques au sein des kingdoms Fungi, Viridiplantae, et Metazoa révèle des profils biochimiques marqués par une prédominance significative de prenol lipids dans tous les trois royaumes, bien que dans des pro-

portions variables. Cette prédominance des prenol lipids, qui varie de 28.3% chez les Fungi à 46.5% chez les Viridiplantae et 43.1% chez les Metazoa, souligne leur importance universelle dans les mécanismes biologiques tels que la construction des membranes cellulaires, la signalisation, et la synthèse hormonale.

Fungi : Bien que les prenol lipids soient prédominants, la diversité des classes chimiques est notable, avec une présence significative d'organooxygen compounds et d'autres classes telles que les indoles et les carboxylic acids. Cette diversité reflète les stratégies écologiques complexes des champignons, notamment leur capacité à interagir avec leur environnement via des métabolites secondaires variés.

Viridiplantae : La domination des prenol lipids est encore plus marquée, ce qui est cohérent avec leur rôle central dans la photosynthèse et la protection contre les stress environnementaux. Les flavonoïdes et autres organooxygen compounds complètent ce tableau, contribuant à la défense contre les UV et les herbivores.

Metazoa : Ici aussi, les prenol lipids dominent, mais la présence notable de stéroïdes souligne leur importance dans la régulation hormonale et le métabolisme des lipides chez les animaux. Les indoles et leurs dérivés reflètent l'importance de ces composés dans les processus neurochimiques et le développement.

En résumé, cette analyse comparative met en lumière non seulement des traits biochimiques partagés, mais aussi des spécialisations uniques adaptées aux niches écologiques de chaque royaume.

En utilisant la fonction df.describe(), nous obtenons un aperçu détaillé des variables quantitatives de notre dataset, ce qui nous fournit une description exhaustive des colonnes concernées. Pour une meilleure visualisation de ces données, nous allons générer des boxplots combinés. Nous avons ensuite normalisé les données des graphiques pour s'échelonner de 0 à 1, permettant ainsi une comparaison plus aisée entre les différentes variables.

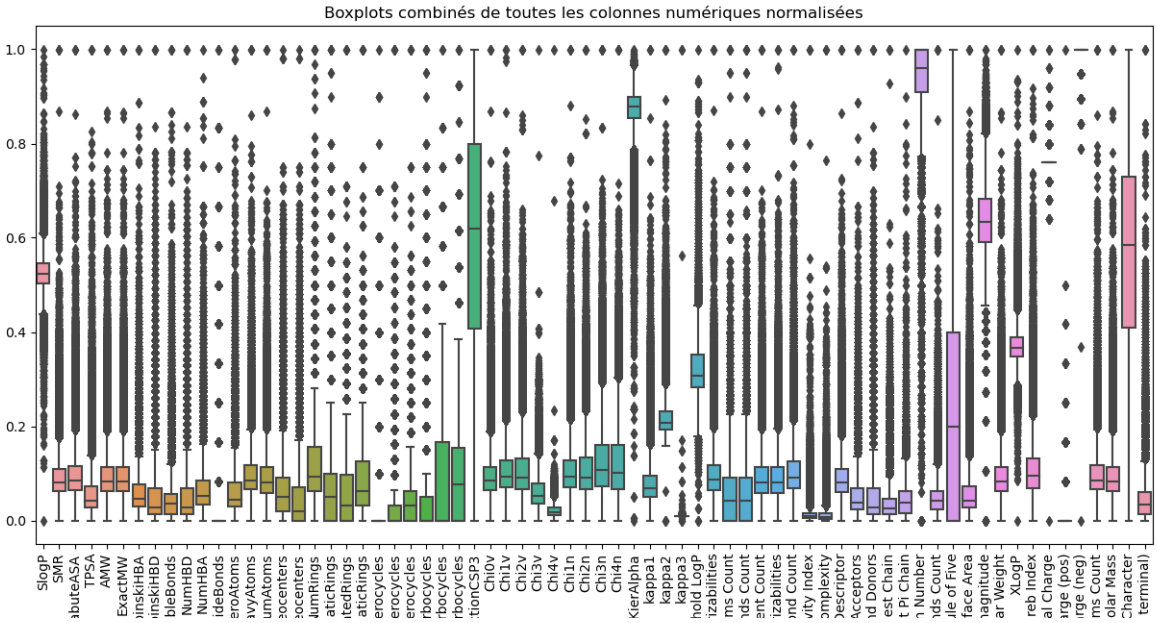

Les boxplots générés révèlent une diversité significative dans la distribution des données normalisées. Certains attributs présentent une large distribution, comme le confirme les boîtes allongées, ce qui indique une variabilité considérable. À l'inverse, les boîtes plus courtes suggèrent une variation moindre. Les points situés hors des moustaches, identifiés comme des valeurs aberrantes, sont fréquents et pourraient révéler des anomalies ou des particularités spécifiques à notre dataset. La position des médianes varie également d'un attribut à l'autre, certaines étant centrées tandis que d'autres sont nettement décalées vers le haut ou le bas de la boîte, révélant des distributions asymétriques. Toutes les données ayant été normalisées entre 0 et 1, ces boxplots facilitent la comparaison directe des variables sur une échelle uniforme.

Ces visualisations sont cruciales pour une compréhension approfondie des propriétés statistiques des différentes variables et pour identifier celles qui pourraient nécessiter un nettoyage supplémentaire pour gérer les valeurs aberrantes.

En se fondant sur cette analyse descriptive, nous allons désormais aborder l'analyse de corrélation. Cette prochaine étape nous permettra de déceler les relations potentielles entre les variables, d'examiner la force et la direction de ces associations, et d'évaluer dans quelle mesure les variables interagissent les unes avec les autres.

Après avoir examiné la distribution et la variabilité des variables à travers les boxplots normalisés, nous passons à une étape cruciale de notre analyse : l'étude des corrélations entre les variables. Cette analyse de corrélation est essentielle pour identifier les relations intervariables qui peuvent influencer nos interprétations et décisions ultérieures.

Les corrélations, mesurées ici à l'aide du coefficient de Pearson r qui est défini par la formule :

$$r = \frac{\sum_{i=1}^{n}(X_i - \overline{X})(Y_i - \overline{Y})}{\sqrt{\sum_{i=1}^{n}(X_i - \overline{X})^2}\sqrt{\sum_{i=1}^{n}(Y_i - \overline{Y})^2}}$$

où X_i et Y_i représentent les valeurs de deux variables pour la i-ème observation, $\overline{X}$ et $\overline{Y}$ sont les moyennes de ces variables, et n est le nombre total de paires de données observées.

Nous permettent de comprendre comment les différentes variables de notre dataset interagissent entre elles. Un coefficient positif indique que les variables augmentent conjointement, tandis qu'un coefficient négatif suggère que l'augmentation de l'une correspond à la diminution de l'autre. Ces informations sont particulièrement utiles pour détecter des facteurs potentiellement redondants ou pour mettre en évidence des relations causales ou associatives qui méritent une exploration plus approfondie.

En reliant cette analyse aux visualisations précédentes, nous pouvons mieux cerner les variables qui non seulement présentent des valeurs aberrantes ou des distributions asymétriques mais qui sont également fortement corrélées avec d'autres variables. Cela peut nous aider à déterminer les variables les plus pertinentes pour nos modèles prédictifs ou pour des analyses ultérieures. En identifiant et en comprenant ces corrélations, nous pouvons ainsi optimiser nos stratégies de nettoyage des données et d'amélioration de la qualité de notre modèle.

Passons maintenant à une discussion détaillée des résultats de cette analyse de corrélation pour voir comment ces interdépendances pourraient affecter notre compréhension globale du comportement des données.

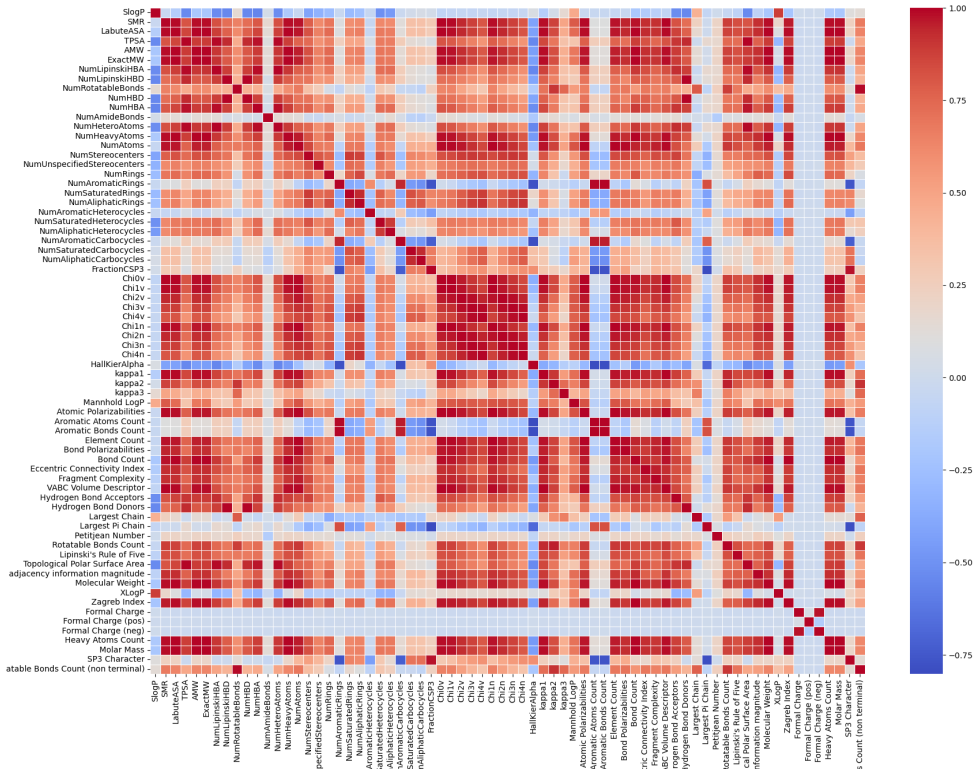

En examinant la matrice de corrélation, plusieurs points clés émergent :

Corrélations Fortes : Il y a des blocs de variables fortement corrélées, ce qui peut indiquer des groupes de features ayant des comportements similaires ou partageant des influences communes. Ces corrélations fortes suggèrent des opportunités pour réduire la dimensionnalité des données, par exemple, en utilisant l'analyse en composantes principales (PCA) ou d'autres méthodes de réduction de features.

Voici quelques exemples :

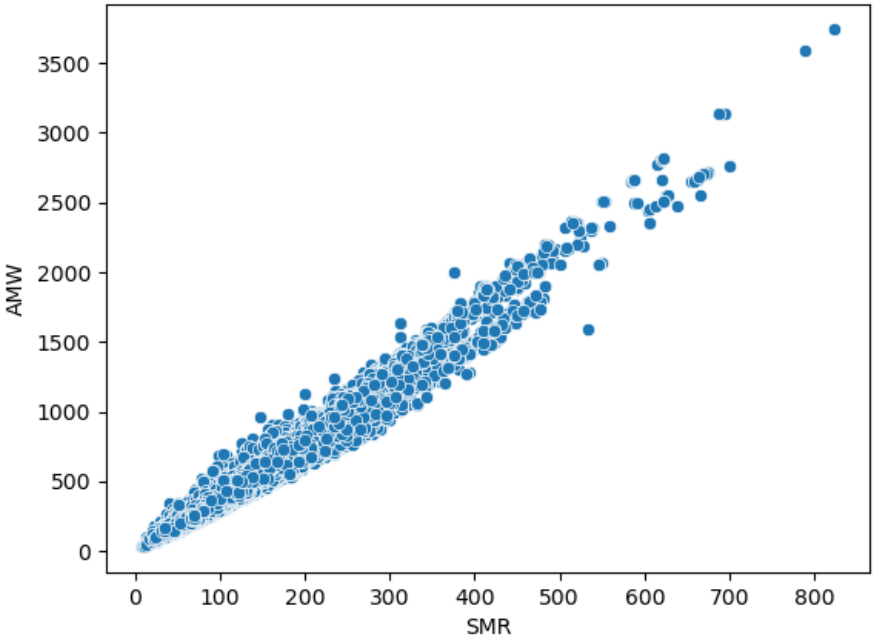

On observe une relation linéaire positive très forte entre SMR et AMW. La plupart des points suivent une ligne droite ascendante, indiquant que l'augmentation de SMR est systématiquement associée à une augmentation de AMW. Cette forte corrélation suggère que les valeurs SMR et AMW sont probablement proportionnelles, ce qui indique que des composés avec des masses moléculaires plus élevées ont tendance à avoir des valeurs SMR plus élevées. Ceci est logique, car SMR mesure la masse moléculaire réfractaire et devrait donc augmenter avec le poids moléculaire.

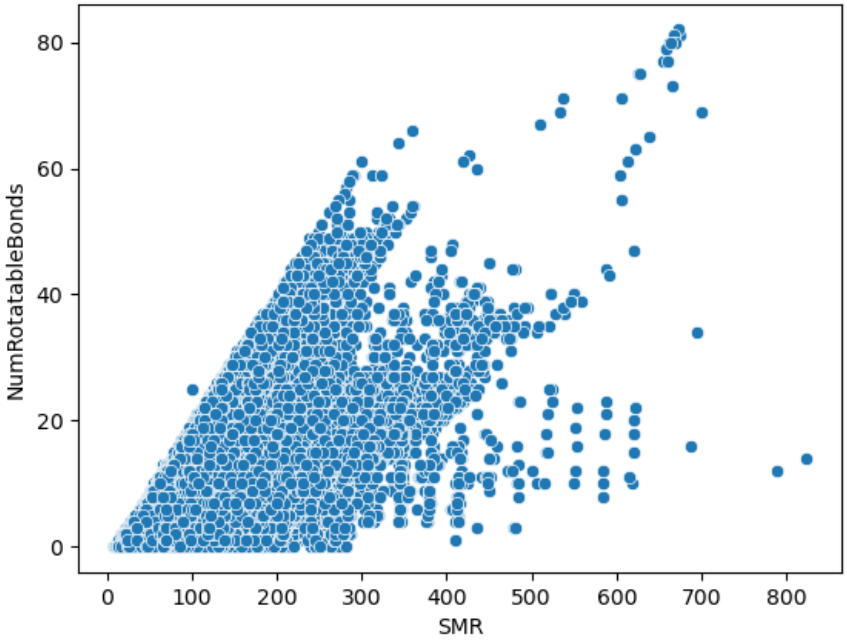

La relation entre SMR et le nombre de liaisons rotatives montre une tendance générale positive, mais avec une dispersion notable des points, surtout pour des valeurs plus élevées de SMR. : Il semble que pour des valeurs faibles à modérées de SMR, le nombre de liaisons rotatives augmente régulièrement, mais cette relation devient moins prédictive pour des valeurs plus élevées de SMR. Cela peut indiquer que d'autres facteurs influencent le nombre de liaisons rotatives dans les molécules de plus grande taille ou de structure plus complexe.

On peut donc conclure avec ces 3 exemples que le SMR est fortement lié à des caractéristiques structurelles des molécules telles que le poids moléculaire (AMW), le nombre d'atomes lourds, et dans une certaine mesure, le nombre de liaisons rotatives. Ces relations confirment que SMR est un bon indicateur de la taille et de la complexité moléculaire. Cependant, la dispersion observée dans les graphiques, en particulier pour NumRotatableBonds, suggère que des analyses supplémentaires pourraient être nécessaires pour comprendre pleinement les interactions complexes dans les molécules plus grandes ou structurellement diverses. Ces résultats justifient l'utilisation de méthodes de réduction dimensionnelle telles que l'ACP pour mieux comprendre et visualiser les relations entre ces variables et pour potentiellement identifier des facteurs latents influençant ces caractéristiques.

Corrélations Faibles ou Négatives : Certaines variables montrent peu ou pas de corrélation, voire des corrélations négatives. Cela peut indiquer que ces variables contribuent de manière unique à l'information dans le dataset, ou qu'elles reflètent des phénomènes distincts qui pourraient être exploités séparément dans

des analyses ou des modèles spécialisés.

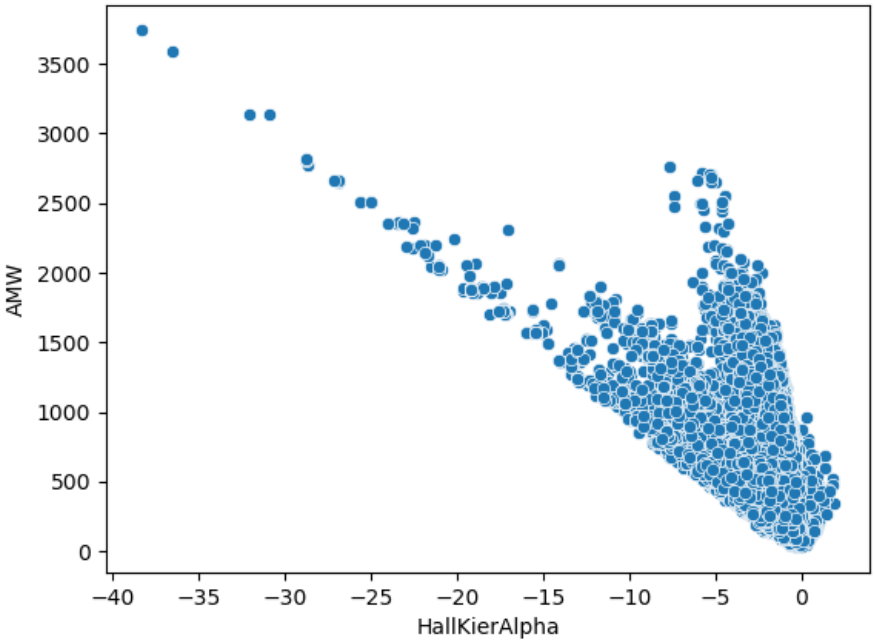

Ce graphique montre une relation complexe entre HallKierAlpha et AMW. Il semble y avoir une tendance générale où le poids moléculaire moyen diminue avec l'augmentation de HallKierAlpha, surtout à partir de valeurs de HallKierAlpha proches de zéro vers des valeurs plus négatives. La distribution des points suggère une variabilité importante dans les valeurs de AMW pour un même HallKierAlpha, en particulier à des valeurs moins négatives.La relation décroissante indique que des valeurs plus élevées de HallKierAlpha (moins négatives) pourraient être associées à des molécules plus petites en termes de poids moléculaire. Cette tendance pourrait indiquer que HallKierAlpha, qui mesure l'accessibilité topologique et la densité électronique, augmente quand les molécules deviennent plus compactes.

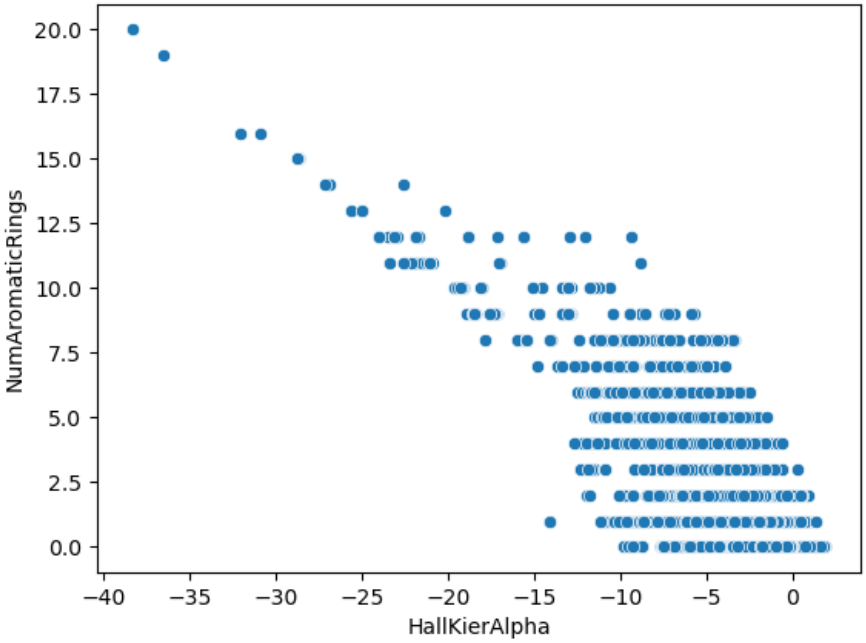

Le graphique montre une large dispersion des points, avec un léger regroupement en plateaux distincts de nombre d'anneaux aromatiques, particulièrement visible pour des valeurs de HallKierAlpha moins négatives.Le nombre d'anneaux aromatiques semble être modérément associé à HallKierAlpha, avec quelques regroupements indiquant des valeurs communes de NumAromaticRings pour des plages spécifiques de HallKierAlpha. Cette observation suggère que la structure topologique et le degré de saturation aromatique pourraient influencer ou être influencés par HallKierAlpha. Les graphiques illustrent que HallKierAlpha est potentiellement un bon indicateur de certaines caractéristiques moléculaires comme la taille et la structure aromatique. La relation avec AMW et NumAromaticRings, bien que pas parfaitement linéaire ou simple, montre des tendances qui pourraient être exploitées pour inférer des propriétés moléculaires ou concevoir des molécules avec des propriétés désirées. La variabilité observée, surtout dans la relation avec AMW, indique aussi que d'autres variables ou caractéristiques moléculaires peuvent interagir avec les effets mesurés par HallKierAlpha, soulignant la complexité de prédire les propriétés moléculaires basées uniquement sur des descripteurs simples.

Ces observations justifient une analyse plus approfondie, peut-être par des techniques de modélisation multivariée ou des méthodes de clustering pour mieux comprendre les relations et pour isoler les effets d'autres variables cachées ou confondantes.

Impact des Valeurs Aberrantes : Les valeurs aberrantes observées dans les boxplots pourraient avoir un impact sur les corrélations observées. En parti-

culier, des corrélations inhabituellement élevées ou basses pourraient être influencées par ces extrêmes. Il serait pertinent d'examiner si l'élimination de ces valeurs aberrantes modifie de manière significative les coefficients de corrélation, ce qui pourrait indiquer une robustesse variable des corrélations détectées.

Après avoir exploré et identifié des patterns de corrélation significatifs parmi les variables de notre dataset, il apparaît nécessaire de simplifier la complexité des données tout en préservant autant que possible l'information essentielle. L'Analyse en Composantes Principales (ACP) se présente comme un outil statistique puissant pour atteindre cet objectif. Cette technique de réduction dimensionnelle nous permettra non seulement de diminuer le nombre de variables en jeu mais aussi de minimiser les problèmes de multicollinéarité révélés par notre analyse de corrélation.

L'ACP transforme les variables corrélées originales en un nouveau set de variables non corrélées appelées composantes principales. Ces composantes sont obtenues de manière à capturer le maximum de variance présente dans les données, ce qui facilite la détection et l'interprétation des structures sous-jacentes qui pourraient rester cachées dans les données de haute dimension.

En appliquant l'ACP, nous espérons révéler les axes principaux de variation des données, ce qui simplifiera les analyses futures, telles que la classification ou la régression, en réduisant le bruit et en accentuant les tendances les plus informatives. Cette transition vers l'ACP est donc une étape naturelle et stratégique pour affiner notre compréhension du dataset et améliorer la précision de nos modèles prédictifs.

2.3 Application de l'Analyse en Composantes Pricipales (ACP)

Après avoir appliqué l'Analyse en Composantes Principales (ACP) à notre dataset, nous avons pu identifier les composantes principales qui capturent l'essentiel de la variance dans les données. Cette réduction dimensionnelle nous permet non seulement de simplifier l'analyse mais aussi de clarifier les structures sous-jacentes qui influencent les comportements observés dans notre ensemble de données.

En examinant les scores des premières composantes principales, nous observons que certaines tendances et regroupements deviennent apparents, ce qui n'était pas immédiatement visible dans l'espace de données original. Cela suggère que les variables initiales sont possiblement corrélées de manière complexe, et que l'ACP a réussi à extraire et à mettre en évidence les relations fondamentales.

Pour présenter les résultats nous allons nous intéresser à un outil très souvent utilisé lorsque l'on fait une Analyse en Composantes Principales, c'est le cercle des corrélations. Un cercle de corrélation est un outil visuel utilisé principalement dans l'analyse en composantes principales (ACP) pour représenter les

corrélations entre les variables originales et les nouvelles composantes principales

2.3.1 Résultats

Analyser les résultats de l'Analyse en Composantes Principales (ACP) implique de comprendre la variance expliquée par les différentes composantes, ainsi que l'interprétation des représentations graphiques des individus et des variables. Voici une analyse des résultats que nous avons obtenus :

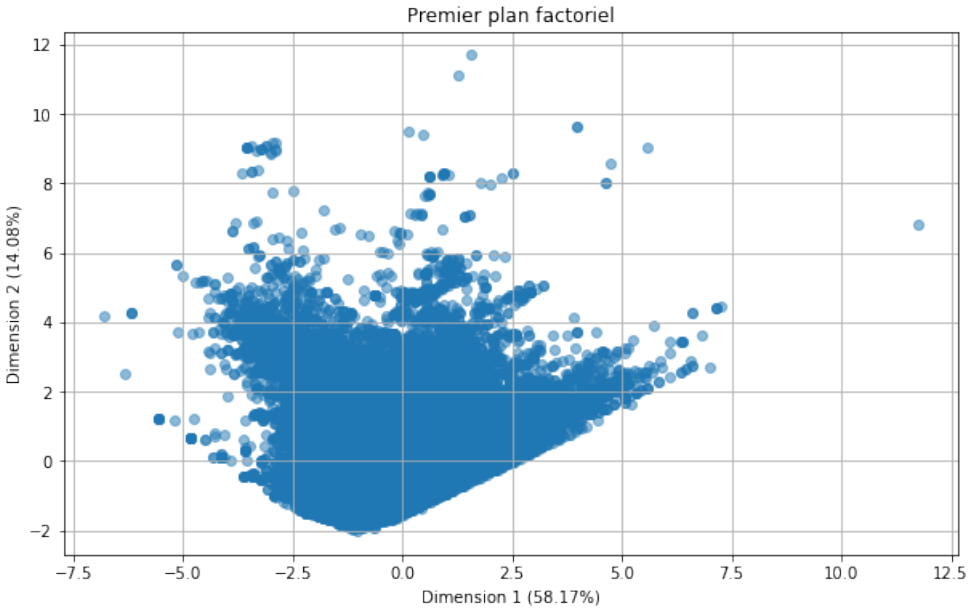

Ce graphique nous indique que les dimensions choisies (dimension 1 et dimension 2) expliquent à elle deux environ 72.26% de la variance totale des données. C'est un bon pourcentage, indiquant que ces deux composantes principales capturent une part significative de l'information contenue dans les données originales.
Nous voyons aussi que les points semblent se concentrer principalement autour du centre, avec une dispersion croissante à mesure que l'on s'éloigne de l'origine. Quelques points se trouvent loin du centre, ce qui indique des observations qui diffèrent notablement des autres en termes des variables initiales.

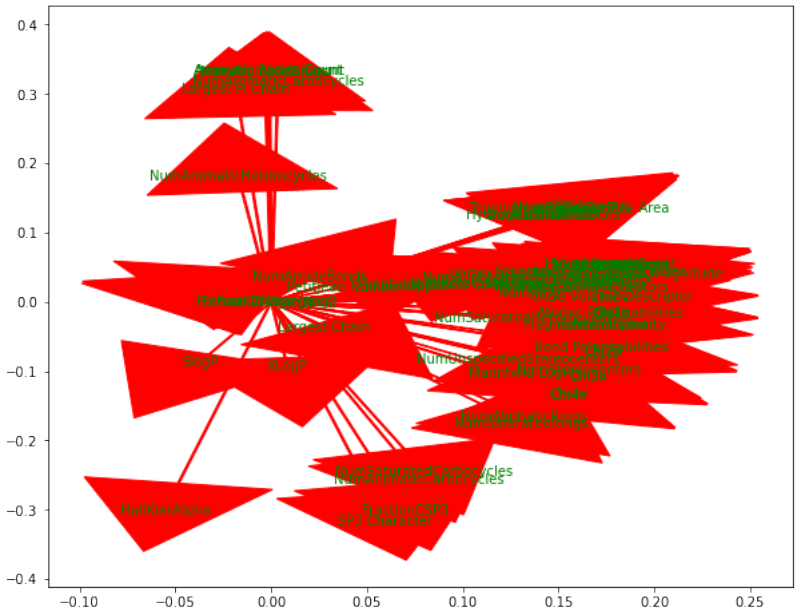

Le graphique montre la projection des variables sur le plan formé par les deux premières composantes principales.

Chaque flèche représente une variable initiale. L'orientation de la flèche montre la direction dans laquelle la variable initiale contribue le plus à la variance capturée par les composantes principales.
La longueur d'une flèche indique l'importance de la variable dans la composante principale correspondante. Ici nous remarquons que la majorité des flèches sont courtes, ce qui implique une faible représentation.
Les flèches proches les unes des autres indiquent des variables qui sont corrélées. C'est le cas pour un grand nombre de nos variables.

Interprétation et conclusion

- **Variance Expliquée** : La majorité de la variance est expliquée par les deux premières composantes principales, ce qui signifie que ces deux axes capturent bien les variations principales des données.
- **Individus** : La concentration des individus autour du centre suggère qu'une grande partie des données est similaire en termes des variables initiales.
- **Variables** : La projection des variables montre quelles variables sont les plus importantes dans les deux premières dimensions. Les variables avec des flèches plus longues et bien séparées des autres sont particulièrement influentes dans ces dimensions. Des variables corrélées apparaissent ensemble, ce qui peut indiquer des redondances ou des regroupements naturels dans les données.

Pour approfondir l'analyse nous avons décidé de nous concentrer sur les 10 individus les plus éloignés.

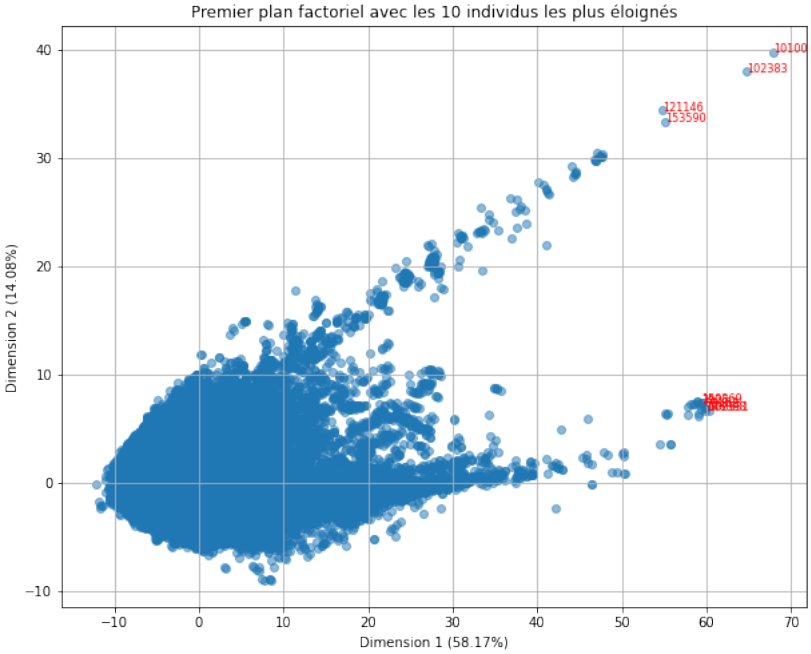

Le graphique montre la projection des individus sur le plan factoriel, avec les 10 individus les plus éloignés du centre mis en évidence en rouge. Nous remarquons que la majorité des individus se concentrent autour du centre du graphique, ils partagent donc des caractéristiques communes et sont assez homogènes. Les individus éloignés se trouvent principalement dans les régions où la variance est plus élevée, ce qui signifie qu'ils contribuent fortement à la variance globale.

2.3.2 Conclusion de l'ACP)

L'Analyse en Composantes Principales (ACP) appliquée à notre jeu de données a simplifié la complexité des données tout en conservant une part importante de la variance totale. Les deux premières composantes principales expliquent ensemble 72,25 % de la variance totale, avec 58,17 % pour la première dimension et 14,08 % pour la deuxième. Cet outil s'est révélé puissant pour explorer et comprendre notre jeu de données. Il a simplifié la structure des données, mis en évidence des relations importantes entre les variables et identifié des individus atypiques. Ces résultats sont essentiels pour permettre des investigations plus approfondies et spécifiques sur nos données.

Chapitre 3

Conclusion

L'étude des distributions des classes chimiques dans les kingdoms Fungi, Viridiplantae, et Metazoa via l'Analyse en Composantes Principales (ACP) a révélé des adaptations biochimiques distinctes, essentielles pour comprendre les processus écologiques et métaboliques des organismes. La prédominance des prenol lipids met en lumière leur rôle crucial dans des fonctions biologiques fondamentales telles que la construction de membranes, la signalisation cellulaire et la synthèse hormonale, démontrant une base biochimique commune malgré la diversité des formes de vie.

Cette recherche a montré comment les techniques avancées de data science peuvent clarifier des ensembles de données complexes et poser des bases solides pour prédire l'origine biologique des organismes en se basant sur leur composition chimique. La simplification des données via l'ACP a permis de découvrir des insights pertinents sur les relations entre les composants chimiques et les traits biologiques des organismes.

Avec plus de temps, nous aurions pu étendre notre ACP à cinq dimensions pour capturer une variance encore plus grande et identifier des relations supplémentaires entre les composés chimiques et les organismes. D'autres méthodes apprises au cours de l'année auraient pu être utiles comme l'algoritmhe des k plus proches voisins, qui utilise la proximité pour classifier ou prédire les caractéristiques d'un point.

En regardant vers l'avenir, une problématique fascinante émerge : la prédiction et la synthèse de nouveaux composés bioactifs basés sur les profils chimiques observés. Cette direction offre une opportunité d'exploiter notre compréhension de la chimio-diversité pour des applications pratiques telles que la création de nouveaux médicaments ou de suppléments alimentaires.

Cette perspective renforce l'importance de poursuivre la recherche en biochimie écologique et en biotechnologie, afin de transformer ainsi nos connaissances fondamentales en solutions concrètes et bénéfiques pour la société et l'environnement.

Chapitre 4

Bibliographie

https ://datagrok.ai/help/datagrok/solutions/domains/chem/descriptors

https ://datascientest.com/acp

https ://elearning.univ-msila.dz/moodle/pluginfile.php/330403/mod_resource/content/0/COURS %20OEBE%20%281%29.pdf

(Origine, Evolution, Diversité et Biologie des Eucaryotes)